

# 期末專案

資料科學系 - 文字探勘與自然語言處理

指導教授: 吳政隆教授/呂明穎教授

報告人: 黃士倫



# Problem Setting

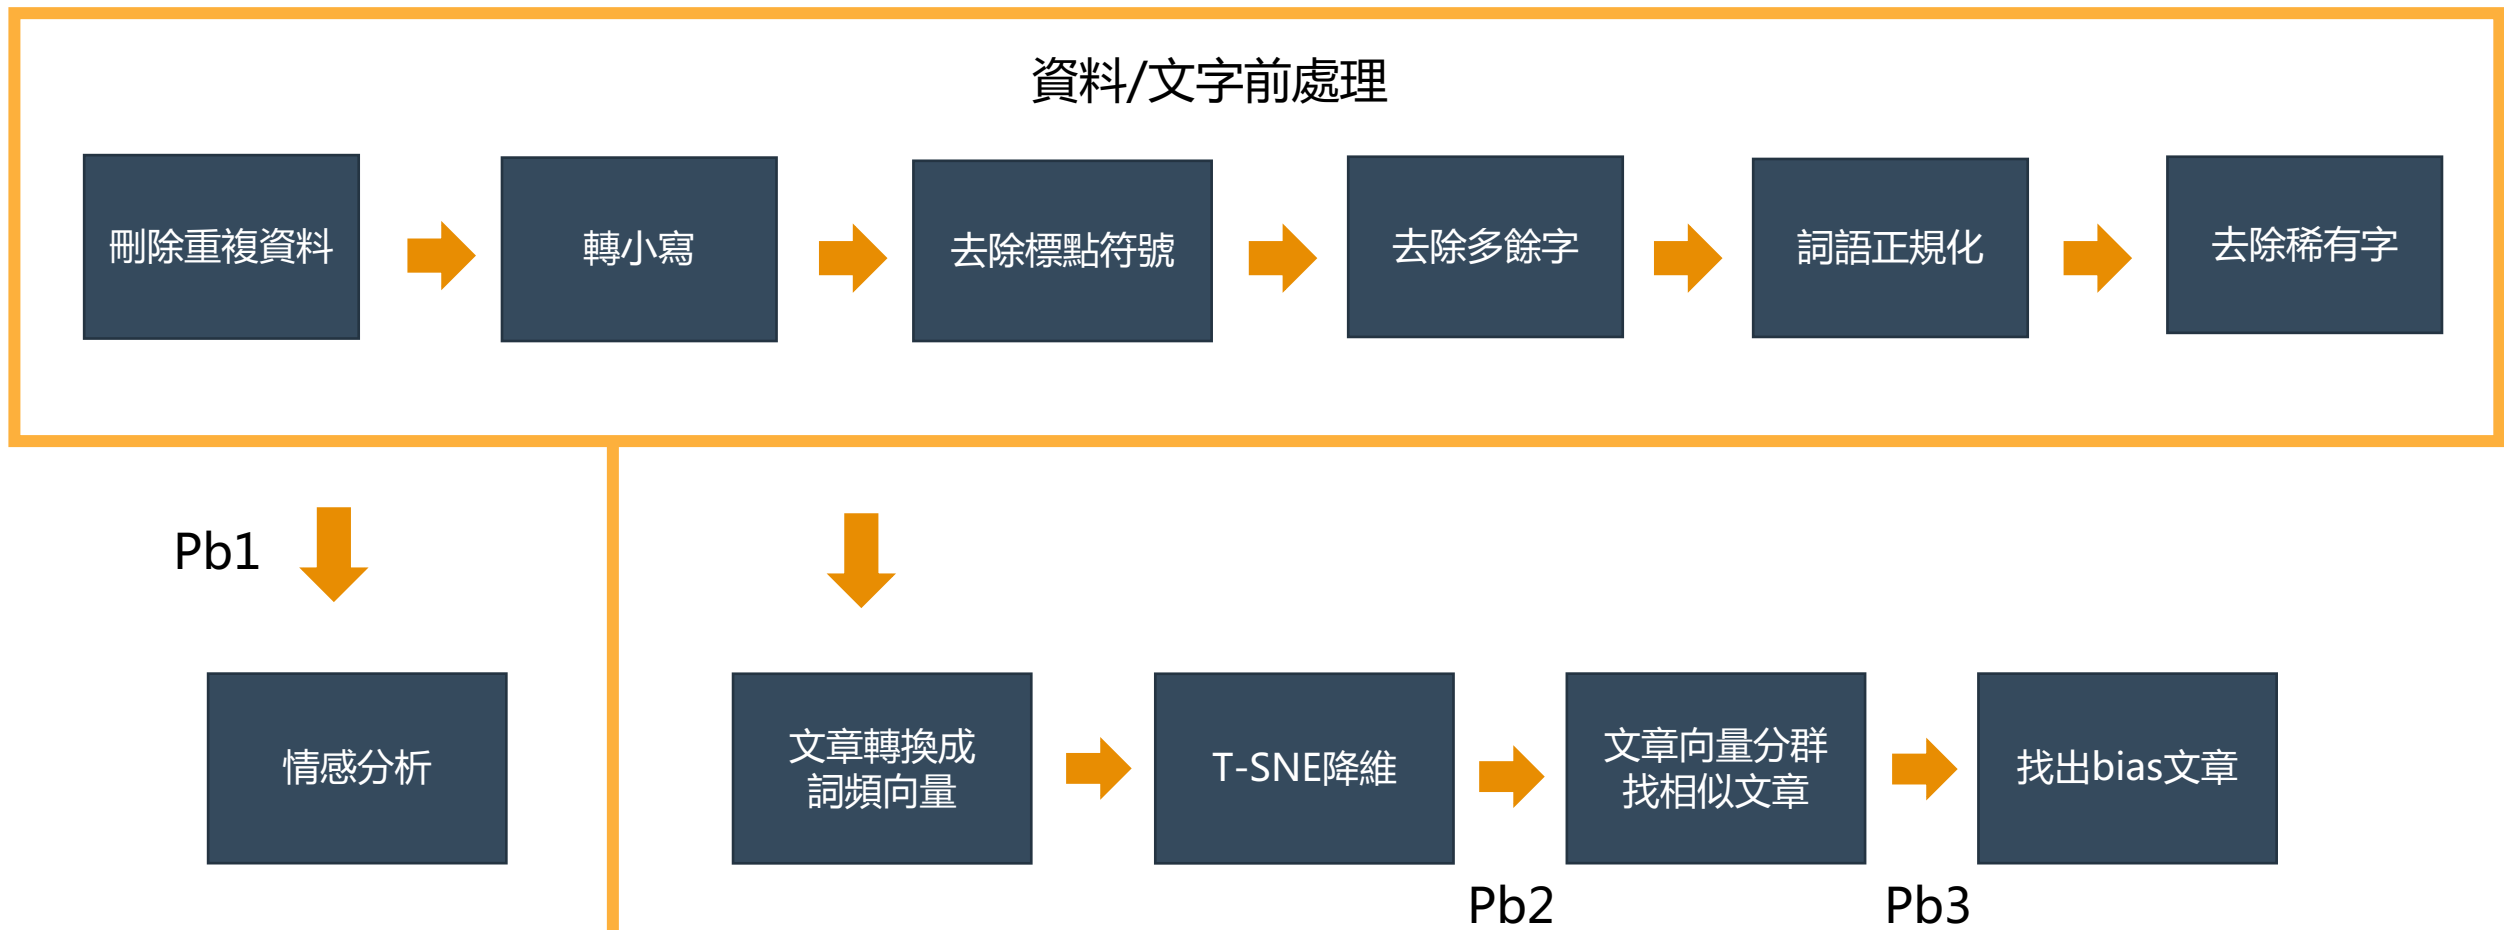
True (News)

☐ Use the sentiment analysis method to label the sentence as positive or negative.

不確定 ☐ Measured by correlation between rows in term-document matrix. Decide how many groups (similar News) topic in this file?

不確定 ☐ There are many different discourses in news. Which news discourses are biased? Try to define and find out those news..

# 流程圖





# 文字前處理

## 文字轉小寫

What -> what...

01

## 去除多餘字

- (1) 去除 : \xa0
- (2) 去除 Stopwords : am、and...

03

## 去除稀有字

所有文章詞頻為 **1** 的詞去除，  
目的：減少維度、拼字錯誤詞

05

02

## 去除標點符號

去除 : ! " # \$ % & \ ' ( ) \* + , - . / : ; < = > ? @ [ \ ] ^ \_ { } ~ " " " "

04

## 文字正規化

- (1) 去除字根 ( stemming ) :  
Ex. started/starting -> start
- (2) 單複數轉換: ( lemmatizing ) :  
Ex. papers -> paper



# 情感分析結果

```
1 from nltk.sentiment.vader import SentimentIntensityAnalyzer
2 nltk.download('vader_lexicon')
3 nltk.downloader.download('opinion_lexicon')
4 senti = SentimentIntensityAnalyzer()
```


使用 nltk 情感分析模組

```
1 senti.polarity_scores(df['text'][0])
{'compound': 0.9756, 'neg': 0.058, 'neu': 0.831, 'pos': 0.111}
```

Pb1: 情感分析結果

比較 positive、negative 決定正負向情感標籤：

- pos > neg : 正面
- neg > pos : 負面
- neg = pos : 中立





## 文章向量

```
1 from sklearn.feature_extraction.text import CountVectorizer
2 tf_vectorizer = CountVectorizer() #0跟1 不然會是tf的值
3 tf_vectorizer.fit(df['text']) #得到欄位名稱
4 tf_X = tf_vectorizer.transform(df['text']).toarray()
```

使用 nltk 詞頻向量模組

	authorit	authoritarian	authorities	authority	autism	autist	auto	autobiographi	autocraci	autocrat
0	0	0	0	0	0	0	0	0	0	0
1	0	0	0	0	0	0	0	0	0	0
2	0	0	0	0	0	0	0	0	0	0
3	0	0	0	0	0	0	0	0	0	0
4	0	0	0	0	0	0	0	0	0	0
...	...	...	...	...	...	...	...	...	...	...
21206	0	0	0	0	0	0	0	0	0	0
21207	0	0	0	0	0	0	0	0	0	0
21208	0	0	0	0	0	0	0	0	0	0
21209	0	0	0	0	0	0	0	0	0	0
21210	0	0	0	0	0	0	0	0	0	0

21211 rows x 33466 columns

欄位為該詞在此文章的  
詞頻(tf)



# 文章向量降維

	0	1
0	-53.784622	23.091883
1	-7.563096	24.868452
2	-37.804489	-32.172546
3	-36.723690	-32.125786
4	-29.592033	-8.233652
...	...	...
21206	1.542265	19.560032
21207	9.875473	43.903984
21208	12.878684	18.930723
21209	8.880972	-22.562115
21210	10.418056	-0.443902
21211 rows x 2 columns		


透過t-SNE 將 **33466** 降維成 **2** 維






# 視覺化結果-1

K-means 手肘法 +  
K-means ( 10群 ) 視覺化結果



**困難**：較難找手肘且  
分群比較不理想（明顯邊界）









## 視覺化結果-2

Pb2:  
文章的大至分成 20 個主題，  
但是未進一步訂定每群主題

輪廓分析法（取大））



階層式聚類分群結果，群數=20






# Bias news

## Bias rule:

subject是 Worldnews 且在第 0,3,9,13 群

subject是 PoliticsNews 且在第 1,10,15,19 群





Pb3: 有 190 篇新聞視為偏誤的文章，其文章內容可能與subject較不符合

[illegible]

# CASE 5

# THANKS

